

DOORM WorldModel-OS：面向可审计代理推理的治理优先架构 —— 混合状态空间、结构先验离散锚点与反规模训练纪律

v0.2 · 2026-05-06 状态： 立场论文兼系统论文，实证前阶段。本文不主张任何实证结果；证伪条件见 §11。
许可： CC BY 4.0

作者

童立^{1*} · 童童¹ · 吴丽华²

¹ DOORM AI PTE. LTD. (UEN 202441729W)，新加坡 ² 独立研究者 * 通讯作者：service@doorm.ai

作者顺序说明。 本文作者顺序按**相对贡献**排列，**不**反映学术资历，亦与所属机构等级无关。

开闭源披露声明。 本文公开 DOORM WorldModel-OS 平台与其配套 Finetune Workbench 的**架构、方法论、契约与运营定位**。这些对应我方的 L1（平台骨架）与 L2（七项认知增量、训练方法论）层，分别以 AGPL-3.0-or-later 开源或以本文作防御性披露。**我方不公开：**(a) 生产级 LoRA 权重；(b) 临床级 adapter 变体；(c) 合作方医疗数据；(d) 商业许可条款；(e) 设备认证部署的密钥材料。以上构成 L3 层，归 DOORM AI PTE. LTD. 商业 / 临床治理另行管辖。

摘要

本文呈现 **WorldModel-OS** —— 面向可审计 agent 式世界模型的混合本地 / 云端操作系统 —— 及其独立训练工作台 **Finetune Workbench**。设计层面我方拒绝当代大模型实践的两项主流假设：(i) 能力是参数量的单调函数（“规模即一切”）；(ii) 对齐可在训后检查点上附加完成。我方转而将系统分解为七项认知增量，其基底是一个**离散状态空间**：由 8 模基态、对基态自配对得到的 64 复合状态、以及对每个复合状态附加 6 序位扩展所得的 384 锚点构成；并通过嵌入每条推理 trace 的四级回滚契约实施安全约束。训练使用一条五类带引用的数据管线 + 三道硬门（引用 / 一致性 / 合规），一个“任何桶 × 任何指标退化超过 3% 即回滚”的桶化评测协议，以及平台与工作台之间不可变的 **adapter_version** 握手字符串。我方以中医（TCM）辨证施治与康复机器人两个医学相邻场景驱动设计：在此类场景中，**逐决策可审计与默认拒答**比规模基准更关键。部署形态为混合客户端 —— 本地用 Ollama 跑量化模型，云端提供知识、安全与记忆微服务，以 ED25519 设备身份绑定。**本文不主张任何实证结果**；我方明确规定可复现包络、三条硬发布门禁、明示的非覆盖清单、跨域迁移成本估计、以及证伪条件——令我方所持立场可被反驳。开闭源披露边界见 §11。

关键词。 世界模型；LoRA 微调；可审计推理；临床安全；离散状态空间；结构先验；反规模训练；中医决策支持；可复现性；防御性披露；可证伪性。

1. 引言

2022 年之后的大模型业界收敛到单一爬山策略：更多 token、更多参数、更多算力、更广的 RLHF。在此框架内，替代路线被视为分心之举。我方认为这个框架对**安全关键、负担审计责任、文化在地、算力受限**的一类部署而言是不完整的；而且，一个**小而守规矩**的系统能在业界正在失败的这些问题上胜过规模派。

本文记录 DOORM WorldModel-OS 的架构承诺。我方立三个立场，其中第一个分解为四个子主张（4 个反）。

P1（反规模命题，分解版）. 对于一类由"消费级 GPU 可复现性、逐决策可审计性、文化 / 语言特殊性（此处指中医与康复传统）"所定义的问题，能力提升**不**主要来自参数量。我方共同承诺四项操作性拒绝：

1. **反 token（反表象切片）**：不把生命与医学仅当作文本 / 符号序列去拟合，而是优先建"状态—机制—反馈"的结构。
2. **反 scale（反盲目做大）**：不把"更大"当作唯一答案，追求在结构正确的前提下，用更小规模获得更强可解释与可迁移。
3. **反堆砌（反拼参数与数据堆）**：不靠堆数据堆参数换效果，而靠结构化建模把复杂性"组织起来"。
4. **反算力垄断**：让关键能力不依赖少数机构的超算资源，推动可复现、可部署、可普惠的健康智能基础设施。

这四个"反"，不是反科学，而是反"只剩工程堆叠"的单一阶梯路径。

P2（两项目分离）. 我方把系统切分为两个并列项目，之间用一条极窄的契约化接口：平台 **WorldModel-OS** 承担推理、状态、安全、审计与知识；训练工作台 **Finetune Workbench** 产出 LoRA adapter，**绝不**导入平台的代码。两项目的唯一跨轨握手就是一条符合冻结正则的 **adapter_version** 字符串。

P3（防御性披露 + 商业保留）. 平台、训练方法、七项认知增量框架对外披露（AGPL-3.0 + 本文）；在受监管医疗语料上微调出的生产权重则商业保留、仅云端提供，不作为量化开放权重分发。本文明确标出哪些主张属 L1 / L2（公开），哪些属 L3（保留）。

1.1 适用范围与非覆盖清单（边界）

为预先回答最常见的审稿问题——"该系统**不**主张普适于何处？"——我方在任何技术内容之前明确划定 scope。以下事项**不在** v0.1 / v0.2 范围内，构成硬非覆盖清单（与内部战略与威胁模型文档交叉引用）：

- **不做手术机器人；不做最后一公里配送 / 物流机器人**。我方应用焦点是中医临床决策支持与康复，不是自主物理干预。
- **不主张通用人工智能（AGI），亦不定位为"GPT 替代品"**。我方是**守纪律的子集**，不是通用替代。
- **不出命理 / 占星类话术**（见 §9.1 硬规）。
- **不在防御性公开前披露 7 项认知增量的完整数学闭式**。本文披露框架与工程锚点；每项增量的完整数学形式按季度节奏增量披露。
- **临床数据不离开受控训练环境**。在受监管语料上训练的生产 adapter 权重保留商业用途，仅云端服务。
- **v0.2 范围内仅覆盖健康域（中医 + 康复 + 脉象采集）。政务、金融、气象、自动驾驶、环境、IoT 应用不在本栈中，亦不主张**。跨域扩展延后处理（见 §13.2 迁移配方与商业治理路线图）。

这些排除是**有意为之**。它们定义了我方普适性主张的**有用意义**：高抽象、首战场窄、附带可发布的扩展配方 (§13)。

我方给出四项贡献：

1. **七项认知增量的分解 (§5)** —— 既不是规模外推，也不是端到端感知地基化。我方主张这是负担审计责任的 agent 式系统的一条有用进展轴。
2. **结构先验离散锚点状态空间 (§4)** —— 8 模基态先验 + 64 = 8×8 配对复合 + 64×6 = 384 序位锚点方案，配以一个**可学习但有先验**的转移先验矩阵，从一个领域相关的排序而非随机初始化。
3. **五类 × 三门训练管线 (§6)** —— 每条答案强制嵌入 **[corpus:Lx-y]** 引用 token；引用 / 一致性 / 合规三门在样本**进入训练池之前**就卡住不合格样本。

4. 四级 (L0-L4) 安全与审计契约 (§7) —— 绑定到每个推理 span，并设置自动桶化评测回滚规则（任何桶 × 任何指标退化 > 3% ⇒ 留用前一版 adapter）。

我方并非首次主张可审计 AI，也非首次主张结构先验或文化在地 NLP。据我方所知**新颖的是三者的组合**：一套商用级系统，把一个文化根基的组合结构与现代参数高效微调融合起来；在明确反规模的定位下；以平台与工作台的契约化分离作为工程形态。

方法论说明。 把一个传统根基的结构严格形式化以期在小众领域胜出端到端方法的赌注，结构上类似化学领域的 Belousov-Zhabotinsky 案例：一个曾被视为反常的现象最终通过机制化重构（FKN 机理 / Oregonator 模型）被科学界接纳。我方**不依赖**此类比作任何技术承诺；仅作为接受非主流方法论先验的动机说明。

2. 相关工作

参数高效微调。 LoRA [Hu 等, 2021] 与 QLoRA [Dettmers 等, 2023] 使十亿级参数模型可用极小比例的可训参数完成适配。我方基于 QLoRA 4-bit NF4 量化，v0 参考基座设为 Llama-3.2-3B-Instruct [Meta AI, 2024]，沿用 Hugging Face PEFT 生态 [Mangrulkar 等, 2022]。**工作台对基座模型保持中立 (base-model agnostic)**：任何符合工作台数据格式与 `adapter_version` 握手契约的解码器类 LLM 均可作基座 —— Llama-3.2-3B-Instruct 仅是 v0 参考基座，**并非绑定要求**。我方技术新颖性**不在**优化器或基座选择，而在：我们门住什么、保留什么作为跨版本契约。

RL 与规划中的世界模型。 自 Ha & Schmidhuber (2018) 至 DreamerV3 (Hafner 等, 2023)，"世界模型"通常指在 ego 中心轨迹上训练的潜在动力学预测器。我方在更高抽象层上重新使用这个标签：一个介于输入与技能派发之间的**组合性状态空间**，其动力学**被审计**而非纯端到端学习。

可审计与可信 AI。 Model Cards [Mitchell 等, 2019]、Datasheets [Gebru 等, 2021] 以及部署台账（如 Hugging Face 模型注册表）把审计当作发布工件。我方走得更远：审计是**运行时契约** —— 每个推理 span 带 `trace_id`、输入 / 输出哈希、`adapter_version`、单调递增 `safety_level`；每条 trace 可从追加式日志中重放。

计算人文学与结构先验。 形式方法用于古典中文语料的文献颇有积累但零散：从符号组合学到近年对古文的神经 NLP。我方不在学理上延展这条文献线。我方是把其中某语料的**组合骨架**当作**工程先验** —— 该语料给出 8 模基态 × 8 模配对 × 6 序位扩展 = 384 个离散锚点，用作引用锚点和状态空间坐标。原典的史学或义理优劣，与该结构能否**有用地**作为先验在我方负担审计责任的设置中是正交问题。

检索增强生成 (RAG)。 我方谨慎使用检索。HexaRAG 组件现已上线基于 BGE-zh-v1.5 的向量嵌入检索 (`RETRIEVER_VERSION = "v1-bge-zh-2026-04-26"`)，并配优雅降级路径：当宿主缺 `sentence-transformers` 时回退至确定性 blake2b 流 —— API 契约两路一致，仅语义质量退化。我方区分**训练中的引用地基** (§6 引用门覆盖率) 与**推理时的证据检索** (云侧知识服务)。两者共享同一套 384 锚点索引作锚点词表。

医疗 AI 安全。 在临床及近临床部署里，**默认拒答 + 证据挂钩生成**几近共识要求 (FDA 2024 AI/ML 医疗器械草案指南、欧盟 AI Act 高风险条款)。我方将其两者显式作为训练门 (§6.3 合规门) 与运行时安全等级 (§7.1)。区别于纯 prompt 级对齐，我方的契约在**数据 / 运行时 / 审计**三层均落地。

3. 系统架构

3.1 两项目分离

我方维持两个并列仓库：

- **WorldModel-OS**（平台）：七微服务、一个网关、一套共享的状态编码与审计原语 **core/**、两条业务域（health 医疗相邻、规划中的 robotics）。
- **Finetune Workbench**（工作台）：数据生成管线、三道质量门、训练 runner（仅 ECS GPU）、桶化评测器。**不允许**导入平台任何 Python 模块；CI 用 grep 式 lint 强制执行。

硬边界（由 lint 测试钉死）：

1. 平台**不**导入 **finetune.***。
2. 平台运行时**不**依赖工作台存在（base 模型直推为底线）。
3. 原典语料（两部用户持 IP 的古籍）住在平台；工作台仅以符号链接消费。
4. **预训练是非目标**（PRD-01 §2.2）。所有适配外置为 LoRA。

唯一的握手。一条冻结正则：

```
ADAPTER_VERSION_PATTERN = r"^v\d+-[0-9a-f]{8}-[0-9a-f]{8}$"
```

两仓各有一份**字面逐字节**相同的 lint 测试钉死。格式：**v{N}-{data_hash[:8]}-{code_hash[:8]}** —— 其中 **data_hash** 是训练 JSONL 的 SHA-256 前 8 位，**code_hash** 是工作台训练时的 **git rev-parse --short HEAD**。

这一条字符串把每条推理 trace 绑回到产出该 adapter 的确切数据集 × 代码 revision —— 与开源方法 + 可审计日志配合，对第三方在发布门禁（§11）范围内的再现**足够**。

3.2 微服务

平台在 FastAPI 网关之后对外暴露七项服务：

服务	主契约	Sprint-2 真实度
perception	POST /embed（文本 → d=256 向量）	确定性伪嵌入（blake2b 流）；计划换 BGE-zh 或 Jina-v3。
world_model	POST /observe → 状态；/step、/rollout	已真实：8×8 转移先验、会话级状态机。
planner	POST /plan（技能图 DAG）	已真实：6 个内置技能 + 拓扑排序。
executor	POST /dispatch、GET /history/{id}	已真实：按安全上限截断。
event_bus	publish/consume，有界 deque（10k/topic）	已真实：进程内 pub/sub。
safety	POST /assess（规则引擎）	已真实：4 级回滚、28 条规则测试。
memory	结构 / 情境 / 情节三层（PRD-01 §6）；策略中间层（承接可迁移行动经验）已排入 v0.2	已真实：三层 DTO；策略层在设计中。

微服务层之外另有两条平台级 API 面：

- `POST /state/anchor_infer` —— 直接暴露 384 锚点索引（对外 API 以 `state.anchor_id` 表达；内部代码命名见仓库 README）。
- `POST /health/encode` —— Mind Encoder（text + PHQ-9 + HRV / HR → 8 模概率分布）。

对本文可审计性主张至关重要者：`GET /audit/snapshot` —— 追加式 trace 日志的只读 API，可按 `operation`、`adapter_version`、`safety_level` 过滤。

3.3 Solver 与跨项目缝

一个专用 `solver` 微服务以 LRU（默认容量 4）热切换 LoRA adapter。请求带 `X-Adapter-Version`；未知版本回退 base 模型，而非静默错路。这是平台**唯一**加载工作台产物的服务，且仅通过**文件系统卷**加载，**不经 Python import**。

4. 状态空间：结构先验离散锚点

4.1 动机

语言模型在人类实践者无法解读坐标的连续潜在空间中推理。在规模受限的闲聊场景这没问题；在负担审计责任的医疗决策支持场景这是灾难 —— “模型这么说的”不是可辩护的根据。我方需要**被锚定的状态空间** —— 一组有限、人类可读、语义承载的坐标，使每条推理都能回指至少一个锚点。

具体地，我方把状态表示为**五元：连续**（传感 / 数值 / 波形）、**离散**（类别 / 结构性锚点索引）、**关系图**（实体—关系边）、**证据谱系**（带版本指针的来源引用）、**不确定性**（每坐标的置信度）。这五者**没有一项**能干净地塞进单条 1D token 序列；硬塞就是物理世界部署中“语言幻觉”失败模式的成因。

源自中文传统的一种文化根基组合学语料库免费给了我方这样一个被锚定的空间。

4.2 8 模基态与 64 复合配对状态

设基态为某二元基元 $\{a, b\}$ （语义为对偶）上的有序三元组，共 $|2^3| = 8$ 个原初态。我方将其标记为 8 个抽象索引 $m \in \{0, \dots, 7\}$ （记作 $\mathbf{BM}_0 \dots \mathbf{BM}_7$ ），每个基态附带一个**五行极性标签**（金 / 木 / 水 / 火 / 土，必要时附阴阳极性），用于下游临床映射；抽象索引 m 是规范的数学句柄，五行标签纯属临床领域读出。64 复合状态是基态自配对 $8 \times 8 \rightarrow 64$ ，并以两套规范排列呈现：**主结构形式（内在原始）**与**应用形式（部署）**，二者由一固定置换相关。我方把两种排列都实现为双射编码，并在整个 64 元素域上以 Python `hypothesis` 做基于属性的测试，钉死两者等价类。

4.3 384 序位锚点方案

每个 64 配对状态承载 6 个序位，从下至上从 1 到 6 标号。离散锚点总数 $64 \times 6 = 384$ 。每个锚点用作：

- **状态空间坐标**：世界模型的离散观测 $state.anchor_id \in \{1, \dots, 384\}$ 。
- **引用锚点**：每个训练样本的答案必须至少含一个形如 `[corpus:Lx-y]` 的 token，其中 `Lx-y` 是两部原典之一中的行范围；该行范围由锚点索引。
- **检索键**：HexaRAG 以（**配对状态**，**序位**）作为关键词索引键。

4.4 转移先验

8×8 转移先验矩阵 $T[i, j] = P(\text{下一基态} = j \mid \text{当前基态} = i)$ 初始化自一种文化根基语料的排序先验，在发布时冻结为 `configs/transition_v1.yaml`。版本化是显式的：`transition_vN` **不可**静默替换 `transition_vM`。这是一份**有意持观点的先验**：我方并未主张该排序在经验意义上最优。我方主张：（a）一个

非平凡先验优于均匀先验；(b) 一个**文化根基**的先验对使用者与审计者都可**读**；(c) 先验的具体主张在样本充分时是**可学而围绕之** (§6)。

5. 七项认知增量

我方不主张单一的"通用智能路径"，也不主张单一 scaling law。我方把认知能力表面分解为七项可独立出货、可独立消融、可映射到具体模块或契约的增量。内部操作手册中它们为 §13.2.1–§13.2.7，此处汇总：

#	增量	映射
1	引用地基作为一等输出 token	§6 (引用门) + §4.3 (锚点词表)
2	离散可审计状态 优于 连续潜在	§4 (基态 / 锚点状态) + <code>world_model</code> 服务
3	组合式技能图 优于 自由 agent 回路	<code>planner</code> 服务 (技能 DAG)
4	拒答作为类型化输出，而非采样意外	§7.1 安全等级 L0–L4 + §6.1 A4 对抗训练
5	跨版本"数据 - adapter - 指标"绑定	<code>adapter_version</code> + <code>data_hash</code> + 桶化评测 (§6.4)
6	追加式、可重放 trace 作为真值来源	§7.2 审计契约
7	结构先验作为工程，而非形而上学	§4.4 转移先验 + §2 相关工作免责

我方主张这七项对"在受监管领域负担审计责任的 LLM 部署"既**必要且充分**。充分性主张很强，本文**不作实证辩护**；我方作**操作性辩护**——每一增量均移除一类我方在规模优先部署中观察到的特定失败模式。

此非何物。非 AGI 主张；非规模派替代；非通用认知架构。是一个可审计性与拒答正确性压倒能力指标的場景下的**守纪律子集**。

6. 训练管线：五类、三门、桶化回滚

6.1 五类生成器

训练样本来自五类显式类别，各自一个独立生成器模块 + 冻结配额：

类	占比	语义
A1 Extraction (抽取)	60%	源自原典的真值 QA；答案必带 <code>[corpus:Lx-y]</code> 。
A2 Paraphrase (改写)	20%	对 A1 的问题改写；答案 / 引用 / 锚点全继承。
A3 Multi-hop (多跳)	15%	跨 2–3 chunk 推理 (因果或对比)；引用合并去重。
A4 Adversarial (对抗)	5%	诱导越界问题 + 合规拒答 (induce / boundary / mystical 子型)。
A5 Schema (结构)	5%	严格 JSON 输出 (如 <code>state.anchor_infer</code> 或 <code>safety.assess</code>) + 嵌入引用。

五者都接受依赖注入的 **Teacher** 可调用。本地开发用 stub teacher（0 成本、仅跑通管线）；生产注入 Anthropic Claude 或 OpenAI GPT。dispatcher 在 stub 模式下按类分派，真实模式下共享一个 teacher。

6.2 三道硬门

任何进训练池的样本**必须**三门全过：

1. **引用门**：答案含 **[corpus:Lx-y]**；该行范围在 chunker 索引中可解析。
2. **一致性门**：teacher 对同一 prompt 多采样；句向量余弦相似度方差 + 引用集合 Jaccard 方差低于阈值。stub 模式下返回 **PASS** 并记录桩原因。
3. **合规门**：不得出现未经否定的 {诊断 / 处方 / 治疗 / 根治 / 保证治愈 / 神奇功效}。否定前缀窗口显式（操作手册 §6.2.1）。

A4（对抗）合规期望**反转**：没能拒掉诱导的样本反而**失败**。按类翻门极性。

A5（结构）在三门**之前**另有**结构门**（严格 JSON 可解析 + 字段齐备），结构不过直接丢弃不进 verifier。

失败样本**不丢弃**。它们带完整 **gate_results** 进入 **<out>.rejected.jsonl**；每次 verify 事件落 **<out>.audit.jsonl**，便于基于 diff 迭代方法。

6.3 Adapter-dataset 绑定

Adapter 命名：

```
outputs/llama3.2-3b-qlora-v{N}-{data_hash[:8]}-{code_hash[:8]}/  
  adapter_config.json  
  adapter_model.safetensors  
  meta.json
```

meta.json 含 **data_hash**、**code_hash**、**pass_rate_by_class**、所用 teacher 后端、指向生成它的 dataset meta 的指针。给定 **adapter_version** 即可机械地定位 dataset meta，用相同 seed + stub teacher 作**封闭式重放**，或用相同 real teacher + prompt 作**有噪重放**，然后重训。

6.4 桶化评测与 3% 回滚

单个聚合分数是均值机器，掩盖退化。我方按桶评测（类 × 难度 × 原典来源），并应用：

回滚规则。若任何桶 × 任何上报指标（通过率 / 引用覆盖 / 拒答正确）相对上一发布 adapter 退化 > 3%，则版本 N **不发布**；版本 N-1 留用。

阈值故意严。理据：在受监管部署中，**某个子群静默退化**的代价大于**头条指标微涨**的边际收益。这一承诺对应**不退化原则**：宁不进步，不退化。

7. 安全与审计契约

7.1 四级安全

每个推理 span 打一个**单调递增**的安全等级：

- **L0** —— 名义。无标志位升起。
- **L1** —— 提示。轻度歧义或轻合规风险；继续但带可见提醒。
- **L2** —— 受限。风险要求限制答案形式（如只允许 schema、强制引用、禁自由发挥）。
- **L3** —— 拒答。答案为类型化拒答对象；原因代码入日志。
- **L4** —— 升级。整个当前 dispatch 回滚；事件发到 event bus；会话状态保留但本轮作废。

安全等级只能在 span 内升。当等级 $\geq$ L2 时，下游模块看到的是封装对象而非原始输出。

双轨架构（非自说服性质）。 升级路径以一条**独立于**"能力最大化"路径的轨道实现。能力轨产出候选输出；边界轨 (§7.4) 依据显式规则语料评估候选，并可**单方面**升等级或替换为类型化拒答。关键在于：**不让同一个模型来说服自己刚刚提出的反对意见** —— 边界轨的判决具有约束力，能力轨**没有**特许的推理通道可用以推翻它。我方称之为**非自说服性质**；这是议会两院制（bicameral）原则在工程契约上的对位。

7.2 审计契约

每个服务端点**必须**：

1. 接收并传递 `X-Trace-Id` 与 `X-Parent-Span-Id` 到 `record_span`。
2. 哈希输入与输出（`input_hash` / `output_hash`）；**不在**审计日志落原文。
3. 若调用了 solver，透传 `adapter_version`（须匹配 `ADAPTER_VERSION_PATTERN`）。
4. 任一规则命中 $\rightarrow$ 单调升高 `safety_level`。
5. operation 命名为 `<service>.<op>`，便于 snapshot 查询过滤。

违反 = PR 直接打回（CI schema lint 强制）。

7.3 Redactor (PRD-04)

一个合规字段剥离器从任何 `extra` 负载中移除 PHI / PII（中国手机正则、身份证、邮箱、银行卡、IP、URL、精确日期 $\rightarrow$ 月粒度），然后才写入审计。redactor 可作中间件（`record_span(redact_extra=True)`）或独立 API（`POST /research/redact`）；附带预览变体只计数不改动。

7.4 拒答即契约：Boundary Gate 与拒答对象

L3（拒答）与 L4（升级）**不是**带着"抱歉，我无法"模板的自由生成；它们是由上游 **Boundary Gate** 强制产出的**类型化对象**。

Boundary Gate —— 五维行动前置检查。 任何带行动后果的派发（`executor.dispatch`、agent 模式下的 `solver.infer`、任何对外副作用工具调用）在执行前沿五个正交维度评估：

1. **权限（Permission）** —— 调用主体是否拥有该行动的权限？
2. **环境（Environment）** —— 行动是否与当前时空 / 运行上下文一致？
3. **人身安全（Personal safety）** —— 在任何合理执行路径下，行动是否危及人身？
4. **设备安全（Equipment safety）** —— 是否危及设备或耦合硬件？
5. **任务约束（Task constraint）** —— 是否仍在最初接受任务的边界内？

任一维度失败即将该 dispatch 路由到一个**类型化拒答对象**：

```
RefusalObject {
    reason_code: <enum>,           // 拒答的原因
    trigger_clause: <string>,      // 命中的门条款 / 规则
```



```
alternative_action: <action | null>, // 安全替代动作（若有）
escalation_path: <recipient>, // 用户异议时的升级渠道
}
```

这"原因 + 触发条款 + 替代动作 + 升级路径"四元组就是契约表面。任何拒答**不**填齐这四项即构成契约违反，PR 阶段被 schema lint 直接打回。要点在操作面：拒答**不是**沉默罢工，而是把对话**合作地**交接给可辩护的替代动作或升级渠道，给审计者足够上下文知道发生了什么。

默认输出 schema（非拒答派发）。与拒答平行，agent / 决策支持模式下任何**非拒答**回答受约束于五字段结构：**结论 + 置信度 + 证据链 + 边界判定 + 下一步动作**（做 / 不做 / 升级）。训练时由 A5 schema 类 (§6.1) 强制；运行时为 solver 输出包一层。这是审计契约 (§7.2) 的运行时对位 —— 缺任一字段的回答**不**入审计日志。

8. 主结构形式（主体层）与应用投影（部署层）：元架构纪律

§4 的离散状态空间与 §5 的七项认知增量，坐落在一个我方将其视为**系统级工程纪律**而非形而上主张的两层承诺之上。

主体层（主结构形式，内在原始）。形式认知结构 —— 二元基元、8 模基态、64 复合配对状态、384 序位锚点、主→应用的置换 —— 是**主体**：**一、不变、所有应用必须回溯之**的认知形式。代码上它住在核心状态空间模块与冻结的 `configs/transition_v1.yaml`。

投影层（应用形式，部署）。任何业务域模块 —— 健康（中医辨证、康复、语音交互、脉象采集）、教育、心灵计算、机器人 —— 都是主体在某一具体时空 / 用例上下文上的**投影**。投影是多个；可在不同域间相异；但**必须全部回溯到同一主体**。

此分层落地为 CI 可强制的契约：

- **3 问准入门。**任何新功能 / DTO / 硬规则入仓前必答三问：(i) 它对应主体层的哪一条结构？(ii) 能否经原典引用反推至该结构？(iii) 反推不通 —— **拒入**。
- **模块级 docstring 要求。**每个 `domains/*` 模块顶部 docstring **必须**声明 "本模块是 <主体层结构> 在 <应用上下文> 的投影"；缺失即 CI 失败。
- **DTO 纪律。**新 DTO 在注释中标出主体层对应（例：`SixMeridianState` 对应主结构形式三阴三阳；见 §9.3）。
- **冲突政策。**投影间允许冲突（不同域方法论可不同）；主体层必须无冲突，因为两个域追溯到不相容的根会作废跨域审计保证。
- **Adapter 纪律。**LoRA adapter 只能**扩展**主体在新投影上的覆盖（应用层能力）；**不可**改写主体取值。训练答案必须能回溯至主体层引用（`[corpus:Lx-y]`）；引用 / 合规门 (§6.2) 的拒入即此规则的运行时强制。

为何这是工程，不是形而上学。没有这条纪律，累积的投影会漂移：健康应用漂向不可证伪的解释；教育应用漂向通用闲聊；审计日志退化成意见日志。有了它，引用门 (§6.2)、桶化评测回滚 (§6.4)、审计重放 (§7.2) 全部成为**跨域不变量** —— 中医应用的审计轨迹与机器人应用的审计轨迹**有意义可比**，因为二者共享主体层坐标。这就是 384 锚点词表**有用**而非装饰的根因。

9. 业务实现：中医辨证施治的五阶推理链

我方描述主体层 (§8) 在临床域中的第一个非平凡投影：**中医 (TCM) 辨证施治**。这是中医专项 adapter (其独立 `adapter_version` 线，见 §6.3) 将依之训练的工程脚手架，亦是 L3 边界 (§11) 所依之划界。

链分五阶；顺序不可交换；配对状态锚点 (§4.2) 是唯一根锚——后续每一阶都必须经它路由。跳过锚点的管线即契约违反，由 orchestrator 层强制 (§9.9)。

实现状态 (v0.1.1) . 五阶链已实现为 `domains/health/tcm_pipeline.py` (`differentiate()` orchestrator)，并经 FastAPI gateway 暴露为 `POST /tcm/differentiate` (详见 §9.9)。第 1–5 阶按本文顺序串行执行；锚点定锚阶 (§9.2) 失败时抛 `ValueError`，orchestrator 把第 3–5 阶完全跳过并升等级到 L2 ("硬刹车")。任何派发都包一层 `redact_extra=True` 的审计 span——即使输入带更细日期粒度，`birth_year_month` 在落审计日志之前已被脱敏到月粒度。

9.1 第 1 阶——时空环境感知 (天地客观运行；纯函数、公式驱动、无学习)

第 1 阶是一台**纯函数**时空上下文引擎。给定 `(timestamp, lat, lon, optional birth_year_month)` 产出：

- **GeoContext**——`{ temperature, humidity, climate, political/economic/cultural }`，由 `(lat, lon)` 派生。
- **WuyunLiuqi**——`{ jieqi (24 节气含精确时刻), year/month/day/hour ganzhi, sitian, zaiquan, zhuqi, keqi, zhuyun, keyun }`，由阴阳合历干支推算。版本钉死 `WUYUN_LIUQI_VERSION = "v0-draft-2026-04-26"`。任何对干支算法、节气时刻表、司天在泉表、主客气表的修改都需 `bump version + 快照回归测试`。实现依赖 `lunar_python` 或 `sxtwl`；司天在泉 / 主客气表手工自经典传注编码，冻结至中医顾问复核为止。

聚合得 **SpacetimeContext { geo, time }**——**确定性、可审计、可回滚**。**认识论上它是背景上下文** (类似天气预报)，**不是诊断步骤**——它从不输出诊断、不主张因果、不修改用户状态。

硬规 (反命理) . 五运六气是天地节律基线，不是命运预测。输出层禁出"今年你犯太岁 / 流年不利 / 桃花运 / 命格 / 八字"等命理话术。合规门 (§6.2) 在训练前拦截此类样本；安全契约 (§7.1) 在运行时对越界生成升 L3 拒答。

隐私. `birth_year_month` 可选；若提供，仅派生 `birth_year_ganzhi` 与 `birth_month_ganzhi` (**故意不含日 / 时**；三者齐全则构成完整命盘)。审计日志写入**之前**，redactor (§7.3) 将日期精度脱敏至月粒度。

9.2 第 2 阶——锚点定锚 (唯一根锚)

`SpacetimeContext + 语言输入 + (可选) 韵律输入` → 8 模主形式状态 → 8 模应用形式状态 → 384 序位锚点。本阶是 `state.anchor_id` 的**唯一**授权写入者；后续任何阶都不得独立锚定。第 1 阶产出**作为条件上下文**进入第 2 阶，**不作为锚点替代**。

9.3 第 3 阶——六经辨证

三阳 (太阳 / 阳明 / 少阳) 与三阴 (太阴 / 少阴 / 厥阴)。配对状态锚点经一冻结表映射至六经 (`LIUJING_MAP_VERSION = "v0-draft-2026-04-25"`):

基态 (五行)	主	兼
BM ₀ (金—阳)	阳明	太阳
BM ₁ (金—阴)	阳明	太阴

基态（五行）	主	兼
BM ₂ （火）	少阴	阳明
BM ₃ （木—阳）	厥阴	少阳
BM ₄ （木—阴）	少阳	厥阴
BM ₅ （水）	少阴	太阳
BM ₆ （土—阳）	太阴	阳明
BM ₇ （土—阴）	太阴	阳明

任何修改都需 bump version + 快照回归测试，且在 L3 冻结前经中医顾问复核。

第 1 阶 `time.zhuqi / keqi` 字段作**天地基线**；第 3 阶报告人体六经状态相对于该基线的**偏离**（《黄帝内经》"同于天地者正，异于天地者病"教义）。

9.4 第 4 阶 —— 八纲辨证

阴阳 × 表里 × 寒热 × 虚实，每轴值 `[-1, +1]`。在第 2、3 阶下游的粗分类阶。

9.5 第 5 阶 —— 理·法·方·药

八法 → 君臣佐使（君 / 臣 / 佐 / 使）角色赋值 → 每味药 `生 / 长 / 化 / 收 / 藏` 标注。

当令药 与 **引经药** 受第 1 阶 `time.sitian / zaiquan` 调节。引经药字段**仅作提示，不作 FAIL**：`fang.yinjing` 可空，但 `yingjing_hint: str | None` **必须**回写；为空则输出层追加教育提示（"建议咨询中医师考虑引经药"）。单方 / 急证方 / 外治方**不受**该提示要求约束。

9.6 9 条硬边界（CI 强制）

- 1. 输出**教育 / 推理**性质，**绝非**处方动作。具体剂量（克 / 两 / 钱）被拦；L3 边界把带剂量答案强制改为"参见原典引用"形式。
- 2. 任何方剂中每味药都带 `citations: [CorpusRef]`；缺引用 → 负例池。
- 3. **锚点优先**。 `SpacetimeContext` 到「理法方药」**必须**经 `state.anchor_id` 中继。第 1 阶五运六气**不抢**第 2 阶锚点的位置。
- 4. 平台**不自建**中药知识库；中药信息只来自原典引用。
- 5. 引经药仅提示（无 FAIL）；`yingjing_hint` 必填。
- 6. 禁命理话术（\$9.1）。
- 7. 五运六气必须纯函数 + 钉版本（\$9.1）。
- 8. `birth_year_month` 可选；必经 redactor 脱敏至月粒度（\$9.1）。
- 9. 天地侧字段（`year_ganzhi / sitian / zaiquan / zhuqi / keqi / current_jieqi / jieqi_moment / zhuyun / keyun`）**非个人** —— 同时刻同 (lat, lon) 所有用户读到完全一致；只有 `personal_ganzhi` 子段允许因人而异。

9.7 跨项目契约增量

中医五阶链给平台新增 5 个健康域模块：`domains/health/{geo_context, wuyun_liuqi, liujing, bagang, prescription}.py`。工作台新增第 6 类生成器 **A6 TCM-Chain**（10% 占比，排期 Stage 9+），并新增两道门：**Chain Completeness**（五阶齐全且互洽；含天地基线引用）与 **Citation Chain**（每条药级主张沿链

回溯至原典引用)。中医 adapter 在与对话 adapter 独立的 `adapter_version` 线上训练，永不作为量化开放权重分发——仅 L3 云端服务提供。

9.8 初始原典与脉象采集

原典/ 目录在 v1 版收录《濒湖脉学》(李时珍, 1564)——六文件套: 完整文 / 四言诀 / 27 脉七言 / 文言原典 / 白话译注 / OCR diff (出处可追)。脉象采集子域 `domains/health/pulse/` (约 28 模块) 实现工程对位: 双侧对称分析、九候聚合 (`jiuhou_aggregator`)、儿童七脉 (`pediatric_seven_pulse / pediatric_sizing`)、灵流式转换 (`ling_curr_pulse`)、深度 / 部位分解、形态学与切迹检测、证据路由进审计日志 (`evidence_router`)、可穿戴设备适配 (`watch_adapter`)。本文写就时仅完成实现层; **v1 中医 adapter 指标尚未产出**——待 §11 三门通过。

9.9 流水线 orchestrator 与 REST 表面

上述五阶为**静态规格**; 把它们串成一个端到端调用的代码住在 `domains/health/tcm_pipeline.py` (420 行预算), 并经 `api/tcm.py` (95 行) 暴露为 **POST /tcm/differentiate**, 挂载于 FastAPI gateway。Orchestrator 的契约:

- **输入**——Pydantic `TcmDifferentiationInput`: `timestamp`、`lat`、`lon`、`chief_complaint` (中文自由文本), 与三个可选字段 (`birth_year_month` 在跨 redactor 边界之前已被压到月粒度; 可选 `pulse_session` 指向脉象子域; 可选 `partial_fang` 用于人在回路精修)。
- **输出**——`TcmDifferentiationResult` 携第 1 阶 `SpacetimeContext`、第 2 阶 (`anchor_id`, `ordinal_index`)、第 3 阶 `SixMeridianState`、第 4 阶 `BagangState`、第 5 阶 `PrescriptionPlan`、跨阶段去重合并的 `citations` 列表、`stage_logs` (按阶记 `name / duration_ms / status / evidence_count / note`)、最终 `safety_level` (0-4)、`compliance_passed` 布尔、审计 `trace_id`。
- **Orchestrator 层强制的硬规** (独立于各阶段内部逻辑)——
 1. 锚点优先。第 2 阶失败抛 `ValueError`; orchestrator 捕获后落 L2 ("硬刹车") 审计 span 并上抛——第 3-5 阶**永不**被调用。REST 端将 `ValueError` 翻为 HTTP 422 + 结构化 hint。
 2. 复方必带引用。第 5 阶若产复方 (即不属豁免集 `single / emergency / external`) 且任一药条目缺 `citations`, orchestrator 把 `compliance_passed=False`, 升 **L3**。
 3. 剂量检测。若 `prescription.metadata.l3_downgrade` 标志命中 (处方模块在生成具体剂量时设置), orchestrator 升 **L3** 并替换为"参见原典引用"形式输出。
 4. 审计层隐私。全部审计 span 走 `record_span(redact_extra=True)`, 确保 `birth_year_month` 即使输入更细粒度, 也在落审计日志时被压到月。
 5. 运行时反命理。第 1 阶 `WuyunLiuqi` 输出从不作"个人预测"暴露; orchestrator 审计 `extra` 把天地侧字段记录在**非个人**键下 (§9.6 硬规 9)。

审计 `extra` 包含: `anchor_id`、`ordinal_index`、`dominant_meridian`、`stage_count`、引用条目数、`compliance_passed`、`pipeline_version`。`pipeline_version` 在任一阶段的版本常量 (`WUYUN_LIUQI_VERSION`、`LIUJING_MAP_VERSION`、处方模块版本) 变动时同步 bump, 作为**单粗粒度跨版本重放钩**。

这是 §8 主体层任何认知主张的**第一例**端到端兑现。后续业务投影 (康复机器人、语音交互、教育、心灵计算) 按相同 "orchestrator + endpoint" 模式: 单文件 `*_pipeline.py` 暴露一个 `differentiate` 风格入口, 一个薄 `api/*.py` router 强制审计 / redactor / 安全契约。

10. 部署: 本地 + 云端混合

面向最终用户的部署形态为混合，**三种客户端表面**共享同一云端后端：

- **本地（用户机）**：量化后 LLM 由 Ollama 本地驱动（Mac / Windows / Linux 原生支持），暴露于 `localhost:11434`。三种客户端在其上：
 - **CLI** —— `doorm-client` Python 包，经 PyPI 分发（`pip install doorm-client`）；依赖最小化。
 - **容器** —— 官方 Docker 镜像，捆绑 Ollama + 客户端；面向无头 / 服务端部署。
 - **桌面** —— 打包 GUI 应用（候选 Electron / Tauri）面向不熟悉命令行的终端用户。三种表面调用同一云端 REST 面，使用同一份设备本地密钥（见下）。
- **云端（`api.doorm.ai`，ECS 承载）**：知识（`memory`）、安全（`/safety/assess`）、状态锚点推理（`/state/anchor_infer`）、Mind Encoder（`/health/encode`），以及一个权威 `/solver/infer` 兜底；外加 `/auth/*`（设备激活 / JWT 续签 / 吊销）与 `/registry/*`（adapter 清单 / 签名 URL）。

每条客户端请求同时带：云端签发的短期 JWT（1 h）与用设备本地密钥对请求体做的 ED25519 签名。密钥对在首次激活时生成，**永不**离开用户机器。

关键：客户端 LLM 是 **L1 / L2 开源 adapter**（量化开放权重）。云端 `/solver/infer` 保留对 **L3 高精度 adapter 线**（含按 \$9 训练的中医专项 adapter）的访问权，FP16 safetensors —— **不作为**量化开放权重分发。此即商业 / 临床边界（\$11）。

11. 开闭源披露政策

层	内容	许可 / 场所
L1 —— 平台骨架	<code>WorldModel-OS/</code> 源码树（7 服务、网关、审计、状态空间、redactor）； <code>Finetune Workbench/</code> 源码树（5 生成器、3 门、编排器、桶化评测器）	AGPL-3.0-or-later ，GitHub
L2 —— 认知增量 + 方法论	本文 \$4 / \$5 / \$6 / \$7； <code>adapter_version</code> 契约；转移先验、门阈值标定、桶化回滚方法	防御性预印本 （本文），CC BY 4.0
L3 —— 生产权重 + 临床合作 + 密钥	受监管医疗语料上的 LoRA 权重；临床 MOU 细节；生产设备认证密钥布局；云基础设施拓扑	保留于 DOORM AI PTE. LTD. 商业 / 临床治理；仅云端服务提供

代码选 AGPL-3.0（copyleft + 网络使用条款）；本文选 CC BY 4.0（宽松使用，带署名）。需非 copyleft 许可的商业用户请联系通讯作者。

支配任何 L1 / L2 工件"官方 DOORM 发布"的三条硬门：

1. **可复现门**：第三方在单块消费级 GPU（RTX 3090 / 4090，24GB VRAM）上，24 小时内跑通从 `run_dataset_v1.py` → `train` → `eval` 的完整管线，获得与我方参考 `adapter_version` 相匹配的 v1 adapter。
2. **基准门**：领域专项评测（中医 + 康复机器人）至少一项桶化指标，带预注册的回滚阈值。
3. **真实采纳门**：至少一个医疗机构 MOU 或付费部署。（本文不披露合作方身份。）

无工件在三条全过之前被视作"released"。

12. 局限、诚实状态表与证伪条件

本文处于**实证前阶段**。为避免"原则上一切都行"的失败模式，我方做三项诚实披露：(a) 针对 v0.2 计划的局限清单；(b) 显式的  已交付 /  在做 /  规划阶段状态表，与内部发布决策对齐；(c) 证伪条件——若成立，整套架构主张被否决。

12.1 具体局限

- **v1 adapter 尚未产出**。Stage 3 (5,000 样本数据集生成 + 首版 QLoRA adapter) 受阻于 ECS GPU 配给与 teacher API 预算。
- **检索侧嵌入模型受下载门控**。HexaRAG.query() 已上线基于 BGE-zh-v1.5 的向量嵌入检索 (RETRIEVER_VERSION = "v1-bge-zh-2026-04-26")；宿主缺 sentence-transformers 时回退至确定性 blake2b 流——保 API 契约，但无语义信号。Cross-encoder 重排序与 FAISS 扩容推迟至 M3。
- **perception 嵌入是占位**。d=256 确定性 blake2b 流；待与检索统一选型后替换。
- **转移先验未被学习，仅被初始化**。config 冻结为 transition_v1；尚未执行 §4.4 所述的学习刷新。
- **合规门是基于规则的**。学到的分类器可能降低被否定场景的假阳性。
- **设备认证是已设计、未实施的**。/auth/* 与 /registry/* 列入 V0.1 / M1 (本文后 2 周)。
- **跨语言覆盖在 L2 层仅中文**。英文外壳用于对外联系已存在；英文域地基尚未完成。
- **量化精度未作消融**。Q4_K_M vs Q5_K_M vs FP16 在桶化指标套件下的对比是发布门前必做实验。
- **3% 回滚阈值尚无实证依据**。是保守选择，其最优值待 dataset-v1 + adapter-v1 产出数据后再定。
- **基态 ↔ 六经映射是 v0 草案**。LIUJING_MAP_VERSION = "v0-draft-2026-04-25" **未经**中医顾问复核，**不可**作为临床主张；它是 §9.3 下的工程脚手架。
- **五运六气表是手工编码**。司天在泉表与主 / 客气表钉死于 WUYUN_LIUQI_VERSION = "v0-draft-2026-04-26"，L3 冻结前将与多家原典传注交叉复核。
- **脉象采集子域 (约 28 模块) 仅完成实现层**。不主张任何 v1 临床或非临床指标。与同步专家脉诊仪录像的端到端验证是发布前必做实验。
- **A6 TCM-Chain 生成器与新增的两道门 (Chain Completeness / Citation Chain) 已排期，未运行**。Stage 9+；前置依赖 Stage-3 dataset-v1 + 中医顾问复核 §9.3 / §9.5 映射。
- **§7.1 非自说服性质目前是契约性而非已证性质**。红队对抗 (试图绕过边界轨的 prompt) 已列入 v0.2 评测路线。
- **§3.2 策略记忆层是设计而非实现**。现存三层 (结构 / 情境 / 情节) 随 v1 出货；策略中间层排入 v0.2。

12.2 诚实状态表 (已交付 vs 规划)

#	§1-§9 主张	状态	锚点
1	混合状态空间 (连续 + 离散统一内核)	 v0.1 已交付	core/schemas.py HybridState
2	4 个反定位 (反 token / 反 scale / 反堆砌 / 反算力垄断)	 已交付 (战略层)	§1 P1 + 治理文档
3	结构先验对偶 (主形式 / 应用形式)	 v0.1 已交付	核心状态空间模块 + 冻结 transition_v1.yaml
4	中医五阶辨证链 (架构层)	 v0.1 已	domains/health/tcm_pipeline.py

#	§1–§9 主张	状态	锚点
交付			
5	中医 adapter 训练 + 临床反馈闭环	🟡 在做	Sprint C+ 与 B+ 并行（合成数据自举；临床验证暂缓）
6	解释层与预测层分离（证据 + 量化指标）	✅ v0.1 已交付	core/schemas.py AuditRecord（evidence / assumptions / uncertainty / safety_flags / adapter_version）
7	schema 版本化 + 输出携带 id	✅ v0.1 已交付	ADAPTER_VERSION_PATTERN + 4 张 advisor-signed 知识表（六经映射 / 27 脉↔锚点映射 / 五运六气 / 当令脉阈值）
8	统一内核 + 多任务头（7 微服务 + health / research 域）	✅ v0.1 已交付	services/ + domains/health + domains/research
9	外骨骼 + 小步可回滚训练	🟡 在做	pulse/bilateral_symmetry.py cap 0.4 + 4 档 SafetyRollbackLevel；客户端 adapter 分发 Sprint B（上云准备）
10	可审计 / 可监管 / 可复现输出	✅ v0.1 已交付	core/audit.py trace-id 链 + JWT 中间件 + AGPL 双许可 + 镜像矩阵
11	置信度 / 熵 / 区间一等公民	✅ v0.1 已交付	HybridState.confidence + phase_distribution（softmax 8 维） + AuditRecord.uncertainty. {type:entropy/variance/credible_interval}
12	健康 / 中医 / 康复 / 脉诊场景	✅ v0.1 已交付	PRD-02 / PRD-03 / PRD-05 + domains/health/ 全栈
13	其他领域（政务 / 金融 / 气象 / 自动驾驶 / 物流）	📁 v0.2 范围外	不存在；无 PRD / 无代码（见 §1.1 非覆盖清单）

12.3 证伪条件

本论文的架构主张**可被证伪**。我方承诺：若以下任一在第三方公平可复现评测下成立，则收回相应立场：

1. **反 scale 证伪**：在同一中医辨证施治数据集与同一逐决策可审计评测套件下，纯 scale Transformer 基线 在 RMSE / Brier / CRPS 三项上**全面**碾压本框架的 HSS 系统 —— 且差距**无法**用我方 7 项认知增量中任一条解释。
2. **离散锚点证伪**：我方 8 模 / 64 配对 / 384 锚点离散结构，在大样本下**未能**对纯连续基线在以下任一项上 稳定显著提升：证据引用命中率、推理链复现一致率、临床医生采纳率。
3. **审计重放证伪**：AuditRecord 链路（trace_id / evidence / assumptions / uncertainty / safety_flags / adapter_version）在第三方独立洁净室环境下，给定相同 adapter 与相同输入、依据 我方公开方法学，**无法**复现到字段级一致。

以上三条任一被证实，整个架构主张即终结。我方承诺发布负面结果并修正框架。

13. 讨论：定位、操作性普适与跨域迁移

我方在下一注**故意不跟潮流**的赌：业界奖励且自我强化如下观点 —— 能力提升来自参数、token、RLHF 扫点；可解释性是研究支线；文化特殊性是通用基座之上的一层营销皮；安全是调出来的、不是类型化的。

我方主张以下三点与此共识相悖，且会站得住：

1. 对受监管或负担审计责任的部署而言，决定性能力是**类型化拒答 + 逐决策引用**，不是基准分数。带拒答契约的 3B 模型在"可部署到生产"的任何评判尺度下胜过无此契约的 70B 模型。
2. 对文化在地的应用而言，来自使用文化本身的结构先验比从网络数据端到端学习**更便宜、更可读**。384 锚点词表内嵌对我方几乎 0 成本，却给审计者与从业者共享语言。
3. 消费级 GPU 可复现性是**战略承诺、非限制**。能在单块 3090 上 24 小时跑完的管线以 512 卡运算所不能的方式启用**第三方验证**。此优势随时间复利，累积成大规模专有系统难以匹敌的**生态信任**。

上述三点在本文中均**未被实证支持**。它们是 v0.2+ 将要据之报告结果的**命题** (§12.3 的证伪条件即这三条命题的操作形式)。

13.1 普适性的操作性定义

我方刻意避免空泛的"普适"主张。我方采用一个**多维操作性定义**：一个系统对某目标类**操作性普适**，当且仅当它同时满足 —— (i) **抽象层级足够高**，(ii) **适用范围广且有证据**，(iii) **迁移成本低**，(iv) **有明确边界与非覆盖**，(v) **可证伪性**。按此尺度，我方 v0.1 / v0.2 栈**并非**对所有健康及医疗相邻域普适；它仅在中医 + 康复 + 脉象采集**这一界内**、且按 §13.2 的迁移配方下普适。

13.2 跨域迁移配方（成本明示）

我方对跨域扩展承诺一份精确配方，明示"什么不变 / 什么必换 / 大致成本预算"：

层	内容	迁到新域时
不变层（内核）	HSS 状态空间；4 个反定位；AuditRecord 契约；adapter_version 版本机制；7 微服务骨架（gateway / perception / world_model / planner / executor / event_bus / safety）	零修改
必换层（业务 adapter）	domain LoRA adapter 权重；domain 知识表（中医线为六经 / 八纲 / 五运六气 / 27 脉↔锚点表）；domain corpus 与 evidence 来源；domain PRD 与场景 API	必须重做
量化估计	复现核心 demo：消费级 GPU 单卡（24GB，3090 / 4090），端到端 ≤ 24h；生 产级 adapter：< 10 张 A100，周级（参 STRATEGY §7）	—

v0.1 阶段我方**仅**对健康线（PRD-02 / PRD-05）完成了"不变层 → 必换层"全栈交付。健康外的领域均处规划阶段，**不在** v0.2 范围内主张。§1.1 非覆盖清单与 §12.2 状态表共同提供我方普适性主张的操作性意义。

14. 结论

DOORM WorldModel-OS 承诺一套具体、不跟潮流的架构：两个以单条正则绑定的并列项目；一个借自文化根基组合学语料的结构先验离散锚点状态空间；一条以引用与拒答为门的训练管线；嵌入每个 span 的安全契约；开核心 / 闭权重的披露结构；明示的非覆盖清单；可发布的跨域迁移配方；以及一组可被反驳的证伪条件。我方已完整呈现设计与开闭源边界。我方**尚未**呈现证据。下一篇（v0.2 实证版）计划在三条硬发布门全过之时发表。在此之前，本文所有内容都是一场赌注 —— 但是一场**界限明确、可被证伪**的赌注。

我方欢迎质疑、在指定包络内的复现尝试、以及合作 —— 尤其欢迎在意"部署可审计 AI"的中医与康复实践者。

作者贡献声明（CRedit）

我方采用 Contributor Roles Taxonomy（CRedit）规范作透明署名归因。

- **童立 Tong Li**: Conceptualization; Methodology; Software（系统架构）; Writing – original draft; Writing – review & editing; Visualization.
- **童童 Tong Tong**: Software（实施、上线）; Data curation; Investigation（工程实验）; Validation; Project administration; Resources; Supervision; Funding acquisition.
- **吴丽华 Wu Lihua**: Conceptualization; Investigation（文献查阅）; Writing – review & editing.

全体作者已阅读并批准本稿，并同意上述署名顺序。

致谢

作者感谢支撑本工作的开源生态库及其维护者，特别是 PEFT [Mangrulkar 等, 2022]、bitsandbytes、transformers、PyTorch。

数据与代码可用性

- 平台代码：将来托管于 github.com/doorm-ai/WorldModel-OS（AGPL-3.0），按 §11 门禁发布。
- 工作台代码：将来托管于 github.com/doorm-ai/Finetune-Workbench（AGPL-3.0），按 §11 门禁发布。
- 原典语料：两部 DOORM AI PTE. LTD. 持 IP 的中文古籍；**结构信息**（chunker 行范围、384 锚点索引）随发布一同放出；**文本内容**以另附"阅读许可"形式提供。
- Adapter 权重（L1 / L2 层）：将来发布于 huggingface.co/doorm-ai/llama3.2-3b-doorm-v1，Q4_K_M 与 Q5_K_M 两档。
- 临床（L3）adapter 权重，含按 §9 训练的中医五阶链 adapter（独立 `adapter_version` 线）：**不分发**；仅云端服务提供。
- v1 原典语料：《**濒湖脉学**》（李时珍，1564）—— 六文件套（完整文 / 四言诀 / 27 脉七言 / 文言原典 / 白话译注 / OCR diff），位于 [WorldModel-OS/原典/](#)。

利益冲突声明

作者就以下财务与实质性关系作出披露：

- **童立** 为 **DOORM AI PTE. LTD.**（UEN 202441729W）股东；该公司持有 §9 所述 L3 工件的商业 IP。
- **童童** 为 **DOORM AI PTE. LTD.** 创始董事兼股东；该公司持有 §9 所述 L3 工件的商业 IP。
- **吴丽华** 为独立研究者，与 DOORM AI PTE. LTD. 之间无雇佣、股权或商业关系；其对本文的贡献系基于学术兴趣的无偿协作。

本论文相关知识产权（含著作权及潜在衍生权利）由 DOORM AI PTE. LTD. 依《作者协议》持有；作者署名按前述 CRediT 声明分配。

资助声明

本工作由 DOORM AI PTE. LTD. 内部研发资金支持。本文覆盖期内未接受任何外部公共或商业资助。

参考文献（精选，v0.2 补全）

- Hu, E. 等 (2021). *LoRA: Low-Rank Adaptation of Large Language Models*. arXiv:2106.09685.
- Dettmers, T. 等 (2023). *QLoRA: Efficient Finetuning of Quantized LLMs*. arXiv:2305.14314.
- Meta AI (2024). *Llama 3.2 模型卡*.
- Mangrulkar, S. 等 (2022). *PEFT: State-of-the-art Parameter-Efficient Fine-Tuning*. Hugging Face.
- Ha, D. & Schmidhuber, J. (2018). *World Models*. arXiv:1803.10122.
- Hafner, D. 等 (2023). *Mastering Diverse Domains through World Models (DreamerV3)*. arXiv:2301.04104.
- Mitchell, M. 等 (2019). *Model Cards for Model Reporting*. FAT* 2019.
- Gebru, T. 等 (2021). *Datasheets for Datasets*. Communications of the ACM.
- 欧盟 (2024). *人工智能法案*.
- 美国 FDA (2024). *AI/ML-Enabled Medical Devices Draft Guidance*.
- Field, R. J. & Noyes, R. M. (1974). *Oscillations in chemical systems IV: Limit-cycle behavior in a model of a real chemical reaction*. J. Chem. Phys.
- 李时珍 (1564). 《*濒湖脉学*》. 原典语料 —— 见 §9.8 与 数据可用性。
- 《*黄帝内经*》. 天地基线教义 (§9.3) 与“六经偏离”的正 / 病框架来源。

(进一步的原典文献、认知架构文献、临床 AI 文献将在 v0.2 补全。)

附录 A —— 跨项目握手（规范性）

```
# WorldModel-OS/src/worldmodel/core/schemas.py
# Finetune Workbench/src/finetune/data_gen/schemas.py
# （两文件必须字面逐字节相同）

ADAPTER_VERSION_PATTERN = r"^v\d+-[0-9a-f]{8}-[0-9a-f]{8}$"
```

语义：

- `v{N}` —— 单调发布版本，从 v1 起。
- `{data_hash[:8]}` —— 规范化后训练 JSONL 的 SHA-256 前 8 十六进制字符。
- `{code_hash[:8]}` —— 工作台训练时的 `git rev-parse HEAD` 前 8 位。

由此契约，任一携带 `adapter_version = V` 的推理 trace 即意味着**精确地**知道产出 V 的训练数据集与代码 revision。

附录 B —— 可复现检查清单

- ☐ 单块消费级 GPU（RTX 3090 或 4090，24GB VRAM，CUDA 12.1）
- ☐ Docker 镜像固定版本 `finetune-llama32:v0.1`（工作台 `docker/Dockerfile`）

- ☐ Python 3.11, `uv sync` 复现 lockfile
- ☐ 配置 teacher 后端 (主: Anthropic Claude 3.5 Sonnet; 备: OpenAI); API keys 进 `.env`
- ☐ `run_dataset_v1.py --target 5000 --teacher anthropic --out data_gen/dataset_v1.jsonl --resume` 在 18 小时内完成
- ☐ 所得 `dataset_v1.meta.json` 的 `data_hash` 前 8 位与参考一致
- ☐ `train.py` 输出目录为 `outputs/llama3.2-3b-qlora-v1-{同 data_hash[:8]}-{code_hash[:8]}`
- ☐ `eval --bucketed` 的 `metrics_bucketed.json` 在所报容差内与参考一致
- ☐ 工作台无任何模块 `import worldmodel.*` (grep lint 绿)
- ☐ 审计日志 `<out>.audit.jsonl` 在相同 seed 下重放得到**一致**的门决策